ML / DS

Хаялиев Раниль

Контакты:

- ranil_h
- +7 927 487 70 22
- ranil05hayaliev@mail.ru
- Ranil-H

Навыки:

Языки: Python, SQL, C++
ML/DL: NumPy, Pandas, PyTorch, Scikit-learn, CatBoost, Matplotlib, Transformers (Hugging Face), ML Flow
Инструменты: Git, Docker, Docker Compose, PostgreSQL, Jupyter Notebook, Linux, Bash

Проекты и достижения

Мультимодальная кластеризация товаров [GitHub]

- **Реализовал систему автоматической кластеризации** 2,400+ объявлений на 10 категорий товаров без использования размеченной выборки (Unsupervised Learning)
- Спроектировал **гибридный пайплайн обработки признаков**: объединил векторы заголовков (**RuBERT-tiny2**) и эмбеддинги изображений с применением взвешенной нормализации
- **Провел снижение размерности данных методом PCA**, сохранив 95% объясненной дисперсии. Это позволило устранить мультиколлинеарность и шум в эмбеддингах, существенно **повысив стабильность** и **скорость работы модели**.
- **Провел визуальный анализ данных (t-SNE)**, подтвердив формирование четких и обособленных кластеров, соответствующих реальным видам товаров
- **Добился высоких метрик на тестовой выборке**: Homogeneity 0.93 и Completeness 0.86, что значительно превысило установленные бенчмарки (0.85/0.8)

Прогнозирование стоимости недвижимости [Kaggle: Top 7] / [GitHub]

- Реализовал пайплайн на базе **CatBoostRegressor**, оптимизированный под работу с низкокардинальным признаком (street_id) и временными рядами.
- Внедрил **продвинутую предобработку данных**: использовал **KNNImputer** для восстановления характеристик зданий и **Log-transform** для нормализации целевой переменной, что **обеспечило стабильность модели** на приватном лидерборде.
- Провел **глубокий Feature Engineering**: настроил **One-Hot Encoding** и масштабирование признаков, а также обработку временных трендов, что позволило модели **эффективно учитывать инфляцию и сезонность цен**.
- Результат: **Занял 7-е место в соревновании на Kaggle среди участников курса VK ML**. Достиг **MAE ~902878**, успешно **обойдя более 80%** участников благодаря качественной очистке данных и подбору гиперпараметров.

Распознавание автомобильных номеров [GitHub]

- **Разработал легковесную систему распознавания текста** для идентификации госномеров **на базе реального кейса Avito**, достигнув **Accuracy 98.4%** на тестовой выборке.
- Спроектировал кастомную архитектуру на основе **ResNet18**: модифицировал предобученную модель, заменив последние 2 слоя на Conv1d-голову. Это позволило эффективно извлекать пространственную последовательность символов из тензоров признаков.
- Реализовал **пайплайн обучения** с применением **Transfer Learning**: настроил **кастомный Learning Rate Scheduler** и оптимизатор **AdamW** для стабильной сходимости в условиях ограниченных данных.
- Внедрил продвинутые стратегии **аугментации данных**: использовал геометрические (**RandomAffine**) и цветовые (**ColorJitter**) трансформации через Torchvision, что существенно повысило обобщающую способность модели.
- **Оптимизировал обработку данных**: разработал логику разрешения семантических конфликтов (символы '0' и 'O') на этапе инференса на основе позиционного анализа структуры номера.

Генерация описаний изображений [GitHub]

- **Разработал нейросетевую архитектуру Encoder-Decoder** для автоматической генерации текстовых описаний к изображениям на базе датасета **MS COCO 2017**.
- **Реализовал гибридную модель «Show and Tell»**: использовал предобученную **Inception v3** (CNN) для извлечения визуальных признаков и **LSTM (RNN)** для моделирования текстовых последовательностей.
- **Оптимизировал процесс инференса**: внедрил сэмплирование с параметром температуры, что **позволило достичь баланса** между грамматической точностью и разнообразием генерируемого контента.
- Провел качественный **анализ работы модели**: выявил и задокументировав влияние смещения данных (Data Bias) на возникновение «контекстных галлюцинаций», что **позволило глубже понять ограничения текущей архитектуры и качество обучающей выборки**.
- Результат: модель **успешно строит связные англоязычные описания**, корректно **идентифицируя доминирующие объекты** и **их взаимодействия на сцене**.

Производственная практика в компании i5.Solutions [GitHub]

- Спроектировал **асинхронный ETL**-пайплайн (**Asyncio, aiohttp**) для сбора данных, ставший фундаментом для разработки предиктивных моделей команды.
- Реализовал модуль **Feature Engineering**: через **Regex** и **Pandas** трансформировал неструктурированные данные (ГОСТы, марки стали, габариты) в чистые обучающие признаки.
- Подготовил качественную выборку для модели регрессии: за счет глубокой очистки и обработки выбросов точность предсказания стоимости (MAPE) **выросла на 15%.**
- Автоматизировал (**Cron**) процессы подготовки данных, обеспечив стабильное дообучение моделей на актуальных рыночных данных.

Образование

МГТУ им. Н.Э. Баумана — *Сент. 2023 - Май 2027*
Системы искусственного интеллекта

ДПО МГТУ, Иннополис, Цифровая кафедра — *Сент. 2024 – Июль 2025*
ML-инженер

VK Education — *Янв. 2025 - Янв. 2026*
ML-инженер

Академия Аналитиков Авито — *Сент. 2025 - Июнь 2026*
DS-инженер

Обо мне

Студент **МГТУ им. Баумана, Академии Аналитиков Авито** и **VK Education**. Победитель стипендиальной программы «**Альфа-Будущее**» за академические успехи (**GPA 5.0**). Имею *сильную математическую подготовку*, владею *PostgreSQL* и *сетевыми технологиями*. Командный игрок, мотивирован на решение сложных задач и создание качественных ML-моделей. Нацелен на развитие в роли ML-инженера или Data Scientist для достижения высоких бизнес-результатов.